

电信客户流失分析与挽留策略

——基于可解释风险评估、经济阈值与压力情景的完整决策链

数学建模校赛 B 题 （匿名内部复核稿）

2026 年 9 月 3 日

摘要

针对电信客户流失识别与挽留资源分配问题，本文将“描述高风险群体—输出个体风险—计算干预边界—应对外部冲击”组织为一条可复核的决策链。对附件中的 7043 条客户记录进行编码、缺失和重复审计后，样本流失率为 26.54%。首先用列联表检验和修正 Cramér’s V 识别关联因素，再以参考类别编码的 Logistic 回归给出可解释概率，并以五折 out-of-fold (OOF) 预测隔离策略评估。模型 OOF ROC-AUC 为 0.8450，留出集 ROC-AUC 为 0.8422；月付合同、光纤服务、电子支票和短在网时长构成的交叉群体 ($n = 440$) 观测流失率达到 75.45%。

题目给定的单次挽留成本、历史成功率和流失损失分别为 150 元、0.35 和 2000 元，因此期望净收益判据为 $pqL - C \geq 0$ ，概率阈值为 0.2143。按 OOF 风险实施阈值策略，选择 3286 人，期望净收益为 630184.63 元，高于全员干预的 253276.19 元。针对竞争对手降价、宏观下行和复合压力，本文以明确标注的 log-odds 扰动进行压力测试；复合压力下预测流失率为 33.89%，稳健正收益集合的逐人净收益下界之和为 506335.09 元。由于数据是横截面且没有干预标签，文中所有风险关系均不解释为因果 uplift，外部冲击参数也不解释为已估计的价格弹性。

关键词：客户流失；Logistic 回归；OOF 预测；经济阈值；稳健挽留；压力测试

1 问题重述与总体路线

题面要求围绕客户画像完成四项工作：**Q1** 找出更容易流失的客户群体并分析因素关系；**Q2** 综合合同、在网时长、月费用和增值服务，给出客户流失判定方法；**Q3** 在每次挽留成本 150 元、历史成功率 35%、单个流失损失约 2000 元的条件下设计策略；**Q4** 在竞争价格和宏观环境变化下检验策略稳健性并给出动态调整方法。本文不把四问拆成互不相连的模型，而是使用图 1 所示的接口：Q1 的群体证据解释 Q2 的特征，Q2 输出的 OOF 概率进入 Q3 的经济判据，Q4 对同一概率的 logit 进行可审计扰动。




图 1: 四个小问之间的模型接口；箭头表示输出量的复用，不表示因果关系。

1.1 题面范围与格式口径

本稿使用用户提供的《校赛 B 题》题面和附件，竞赛版本记为“2026 华中师范大学数学建模竞赛、B 题”。题面未随附件提供可核验的官方论文模板、页数和匿名细则，因此本文的页面参数只服务于数学与结果复核，官方格式状态为待主办方确认。任何投稿前版本都应把本稿内容迁移到当届官方模板，并重新进行渲染审计。

2 数据审计、变量与假设

2.1 数据结构与清洗

附件共有 21 列：客户编码、性别、老年标记、伴侣/家属、在网时长、电话与线路、互联网及五类增值服务、合同与支付、月费用、总费用和是否流失。客户编码只用于本地风险明细，不进入本文的统计汇总。表 1 给出可复核的质量摘要。

表 1: 附件数据质量与目标分布

项目	口径	数值
记录数	行（不含表头）	7043
字段数	列	21
编码	自动探测结果	gb18030
重复记录	完全重复行	0
重复客户编码	ID 重复数	0
流失/未流失	目标计数	1869 / 5174
总体流失率	1869/7043	26.54%
总费用空值	原始空字符串	11
空值处理	在网时长为 0 的空总费用	置为 0

注：11 条空总费用均对应应在网时长 0 个月；没有剩余总费用缺失需要用中位数填补。数值均来自本地求解器的聚合输出。

记第 i 个客户的流失标签为 $Y_i \in \{0, 1\}$ ，其中 1 表示“是”。对于总费用，清洗规则写成

$$T_i^* = \begin{cases} 0, & T_i \text{ 为空且 } U_i = 0, \\ T_i, & \text{其他可解析数值,} \end{cases} \tag{1}$$

其中 U_i 是在网时长（月）， T_i^* 的单位为元。该规则只修正由题面字段组合确定的结构性空值，不对未知缺失作无依据的插补。

2.2 变量注册与可检验假设

表 2 只列出后续公式中反复出现的符号；原始字段与模型字段的完整映射保存在求解器中。

表 2: 主要符号、单位与来源

符号	类型	含义	单位/粒度
Y_i	输入/响应	客户 i 是否流失	无量纲/客户
$\mathbf{x}_i$	输入	合同、服务、费用等画像特征	混合/客户
p_i	输出	客户流失的关联风险概率	无量纲/客户
C	参数	一次挽留干预成本	元/客户
q	参数	对将要流失客户的平均成功率	无量纲
L	参数	一个流失客户的损失	元/客户
d_i	决策	是否对客户 i 实施干预	0/1/客户
$\delta_i^{(s)}$	情景参数	情景 s 的 log-odds 扰动	无量纲/客户

为使结论可被攻击，本文采用以下假设，并在验证章节写明放松方式：

- A1.** 在同一观测截面内，字段定义和标签口径一致；若未来标签窗口改变，模型需重新训练。
- A2.** Logistic 模型只描述条件关联风险，不把系数解释为干预造成的变化；若需要个体化优惠效果，必须补充随机挽留实验。
- A3.** Q3 的 $q = 0.35$ 和 $L = 2000$ 是题面给定的期望参数；Q4 的 δ 、情景成功率和成本是压力假设，不能替代外部冲击数据。
- A4.** 由于附件没有时间、地区、竞争价格和宏观变量，Q4 只提供情景边界与调整规则，不声称识别动态弹性。

3 Q1：流失群体与因素关系

3.1 列联表检验

对每个类别字段 X_j ，将其水平记为 a ，观测频数为 n_{ay} ，边际频数为 $n_{a\cdot}$ 和 $n_{\cdot y}$ 。独立性假设下的期望频数为

$$e_{ay} = \frac{n_{a\cdot} n_{\cdot y}}{N}, \quad \chi_j^2 = \sum_a \sum_{y \in \{0,1\}} \frac{(n_{ay} - e_{ay})^2}{e_{ay}}. \quad (2)$$

为避免样本量很大时仅凭显著性排序，进一步报告修正 Cramér's V：

$$V_j = \sqrt{\frac{\max\left(0, \phi_j^2 - \frac{(k_j-1)(r_j-1)}{N-1}\right)}{\min(k_j-1, r_j-1)}}, \quad \phi_j^2 = \frac{\chi_j^2}{N}, \quad (3)$$

其中 r_j 和 k_j 分别是列联表的行、列数。 V_j 越大，表示该字段与标签的观测关联越强，但不包含时间顺序或干预识别。

表 3: 类别字段与流失标签的关联强度（按 Cramér's V 降序）

字段	水平数	χ^2	p 值	V
合同类型	3	1184.60	5.86×10^{-258}	0.410
在线安全	3	850.00	2.66×10^{-185}	0.347
技术支持	3	828.20	1.44×10^{-180}	0.343
互联网服务类型	3	732.31	9.57×10^{-160}	0.322
支付方式	4	648.14	3.68×10^{-140}	0.303
在线备份	3	601.81	2.08×10^{-131}	0.292
设备保护	3	558.42	5.51×10^{-122}	0.281
电影流媒体	3	375.66	2.67×10^{-82}	0.230
性别	2	0.48	0.487	0.000
电话服务	2	0.92	0.339	0.000

注： p 值仅用于独立性检验；不将统计显著性等同于业务重要性或因果性。完整 16 个类别字段表保存在 `paper/evidence/associations.csv`。

3.2 群体流失率与交叉画像

对群体 G 定义观测流失率

$$\hat{p}(G) = \frac{\sum_{i=1}^N \mathbb{I}(i \in G) Y_i}{\sum_{i=1}^N \mathbb{I}(i \in G)}. \tag{4}$$

图 2 展示合同、互联网、支付和在网时长四个维度；交叉群体的分母和流失率列于表 4。结果显示，月付合同、光纤服务、电子支票和短在网时长分别形成高风险信号；叠加后风险进一步集中。




图 2: 关键群体的观测流失率；每个柱子的分母为该群体客户数，不能单独推出干预效果。

表 4: 代表性交叉群体的观测流失率

群体条件	样本数	流失率
月付合同	3875	42.71%
光纤服务	3096	41.89%
电子支票	2365	45.29%
在网不超过 6 个月	1481	52.94%
月付 + 光纤	2128	54.61%
月付 + 电子支票	1850	53.73%
月付 + 光纤 + 电子支票	1307	60.37%
月付 + 光纤 + 电子支票 + 在网不超过 6 个月	440	75.45%

注：这些是同一横截面中的分组描述；交叉条件可能共享同一潜在机制，不能将各差值相加解释为独立贡献。

因此，Q1 的可操作画像是“月付、短在网、光纤、电子支票、缺少安全/支持服务”的优先核查群体；性别和电话服务在本数据中几乎没有单变量区分度。该画像作为 Q2 的解释层与 Q3 的分层运营入口，而不是绕过概率模型的硬编码结论。

4 Q2：可解释的流失判定方法

4.1 参考编码的 Logistic 风险模型

令数值变量集合为 $\mathcal{N} = \{U, M, T^*\}$ ，分别表示在网时长、月费用和清洗后的总费用；类别变量集合记为 $\mathcal{C}$ 。数值变量以训练折中位数填补后标准化，类别变量以训练折众数填补并对每个字段丢弃一个参考水平。模型的线性预测量和概率为

$$z_i = \beta_0 + \sum_{j \in \mathcal{N}} \beta_j \frac{x_{ij} - \tilde{x}_j}{s_j} + \sum_{j \in \mathcal{C}} \sum_{\ell \neq \ell_{j0}} \beta_{j\ell} \mathbb{1}(x_{ij} = \ell), \quad \hat{p}_i = \sigma(z_i) = \frac{1}{1 + e^{-z_i}}. \quad (5)$$

丢弃参考水平后的系数是相对于 ℓ_{j0} 的条件对数优势比；数值变量的优势比对应增加一个训练样本标准差。参数通过带 L_2 正则的对数损失估计：

$$\hat{\beta} = \arg \min_{\beta} \left\{ - \sum_{i \in \mathcal{T}} [Y_i \log \hat{p}_i + (1 - Y_i) \log(1 - \hat{p}_i)] + \frac{\lambda}{2} \|\beta\|_2^2 \right\}. \quad (6)$$

式 (5) 的概率是判别排序工具。由于总费用、月费用和在网时长存在结构相关，单个系数只能作为条件关联方向，不能被改写成价格或服务变更的因果效应。

4.2 隔离验证与模型选择

采用固定随机种子 42 的分层五折交叉验证：每一折只用其余四折拟合预处理器和模型，再对留出折产生 OOF 概率；所有客户的 OOF 概率拼接后用于校准和 Q3 策略计算。最后再用全体样本拟合一个模型，生成本地运营风险明细。非线性的 HistGradientBoosting 只作为同字段基准，不因模型更复杂就自动替换可解释主模型。

表 5: 风险模型的隔离验证指标

模型/数据	ROC-AUC	AP	Brier	Log loss	精确率	召回率
Logistic, 留出集	0.8422	0.6349	0.1380	0.4203	0.6593	0.5588
梯度提升, 留出集	0.8380	0.6462	0.1385	0.4267	0.6575	0.5134
Logistic, 五折 AUC 均值 $\pm$ 标准差	0.8450 $\pm$ 0.0135					
Logistic, OOF	0.8450	0.6539	0.1356	0.4174	0.6592	0.5527

注: AP 为 average precision; 精确率和召回率使用概率 0.5, 仅用于报告, 不是 Q3 的经济阈值。完整指标和折次保存在 `paper/evidence/model_metrics.json`。

图 3 给出留出集 ROC 曲线。OOF 十分位校准中, 最低到最高风险箱的平均预测概率分别约为 0.0053 和 0.7244, 对应观测流失率约为 1.28% 和 75.89%, 说明概率具有明显的风险分层能力, 但仍需在新时间窗口上复校准。




图 3: 留出集 ROC 曲线; 曲线只衡量本横截面上的区分度, 不是未来时间外推证明。




图 4: 参考类别编码下的主要 Logistic 关联方向; 数值变量已标准化, 系数不代表因果效应。

4.3 判定规则与可解释输出

给定客户画像后, 先按式 (5) 得到 $\hat{p}_i$, 再按照 Q3 的经济门决定是否进入干预候选集。若只需要“高风险/低风险”标签, 可以使用题目成本参数导出的阈值, 而不把 0.5 当成普适标准。模型最终输出应至少包含概率、主要触发特征、参考水平和数据时间窗; 若出现训练时未见的类别, 保留安全的未知水平编码并标记需复核。

5 Q3: 挽留策略与资源分配

5.1 期望净收益判据

对客户 i 实施一次干预的成本为 C 。若客户在不干预时流失的概率为 p_i , 对“将要流失客户”的平均挽留成功率为 q , 每个流失客户损失为 L , 则期望避免损失为 $p_i q L$, 单客期望净收益为

$$g_i = p_i q L - C. \quad (7)$$

对候选集合 S 的总期望净收益为

$$B(S) = \sum_{i \in S} g_i = \sum_{i \in S} (p_i q L - C), \quad d_i = \mathbb{I}(i \in S). \quad (8)$$

当没有容量约束时, 逐人目标可分离, 最优集合为 $S^* = \{i : g_i \geq 0\}$, 即

$$\tau = \frac{C}{qL} = \frac{150}{0.35 \times 2000} = 0.2142857, \quad S^* = \{i : \hat{p}_i \geq \tau\}. \quad (9)$$

当每天只能处理 K 人时, 将 g_i 从大到小排序, 取前 K 人。交换论证很直接: 若集合中有较小的 g_a , 集合外有较大的 g_b , 用 b 替换 a 会使目标增加 $g_b - g_a > 0$, 所以排序截断是容量约束下的最优选择。

5.2 策略比较

表 6 使用同一组 OOF 概率和题面参数比较全员、经济阈值及固定比例策略。 $\hat{p}_i$ 只来自不包含该客户的训练折，避免直接用训练内拟合概率夸大收益。

表 6: 不同挽留策略的期望收益 (OOF 概率)

策略	选择人数	覆盖率	选中组观测流失率	期望避免损失/元	期望净收益/元
不干预	0	0.00%	—	0.00	0.00
全员干预	7043	100.00%	26.54%	1309726.19	253276.19
经济阈值 $p \geq 0.2143$	3286	46.66%	48.23%	1123084.63	630184.63
风险排序前 1%	70	0.99%	85.71%	39711.87	29211.87
风险排序前 5%	352	5.00%	81.25%	187597.37	134797.37
风险排序前 10%	704	10.00%	75.99%	357051.44	251451.44
风险排序前 20%	1408	20.00%	67.40%	649322.14	438122.14

注：期望避免损失使用 $\sum_{i \in S} \hat{p}_i q L$ ，干预成本为选择人数乘 150 元；选中组观测流失率仅作独立的描述性校验，不等于挽留后的实际成功率。

图 5 表明，按经济阈值筛出的集合比全员干预保留了更多净收益。实际运营可采用“阈值筛选—容量排序—分层话术”的两级策略：先排除 $g_i < 0$ 的低收益客户，再在剩余客户中按风险和服务成本排序；对 Q1 的交叉高风险群体优先核查合同解释、光纤服务体验和电子支票支付摩擦，而不是对所有人发送同一优惠。




图 5: 不同干预策略的期望净收益；金额为题面参数下的模型期望，不是已实现现金流。

5.3 参数敏感性

式 (9) 说明成功率下降或单客损失下降都会提高阈值。令 q 取 0.25、0.35、0.45， L 取 1500、2000、2500 元，部分结果见表 7。所有组合仍使用同一 OOF 概率，变化来自经济口径而非重新训练模型。

表 7: 挽留成功率与流失损失的敏感性（代表组合）

q	$L/\text{元}$	阈值 $C/(qL)$	选择人数	期望净收益/元
0.25	1500	0.4000	2103	153341.36
0.25	2000	0.3000	2658	322936.25
0.35	2000	0.2143	3286	630184.63
0.45	2000	0.1667	3773	961295.39
0.45	2500	0.1333	4047	1348110.77

6 Q4: 外部冲击下的稳健策略

6.1 压力情景的构造

附件没有竞争价格、宏观指标或时间序列，不能从数据估计外部冲击系数。为回答“如何调整”而不伪造因果证据，本文把冲击写成透明的 log-odds 压力参数：

$$p_i^{(s)} = \sigma\left(\text{logit}(\hat{p}_i) + \delta_i^{(s)}\right), \quad \text{logit}(p) = \log \frac{p}{1-p}. \quad (10)$$

竞争降价情景对月付、一年、两年合同分别加入 0.35、0.15、0.05；宏观下行情景对全体加入 0.20，在网时长不足 12 个月者再加入 0.05。情景同时改变成功率和干预成本，以检验策略而非只抬高概率。

表 8: 外部冲击情景与结果

情景	平均 logit 扰动	成功率	成本/元	预测流失率	正收益人数
基准	0.000	0.35	150	26.57%	3286
竞争对手降价	0.236	0.33	150	30.79%	3624
宏观下行	0.215	0.30	165	29.63%	3140
复合压力	0.451	0.28	180	33.89%	3252

注：扰动、成功率和成本是压力假设；“正收益人数”表示在该假设下按 $p_i^{(s)} q_s L - C_s > 0$ 的人数，不是实际接受优惠人数。

图4 外部冲击与稳健调整




图 6: 外部冲击与稳健排序；左图为风险水平，右图为逐人最坏净收益下界的累加。

6.2 稳健目标与动态调整规则

令情景集合为 S ，情景 s 下的单客净收益为 $g_i^{(s)} = p_i^{(s)} q_s L - C_s$ 。保守地定义逐人最坏得分

$$r_i = \min_{s \in S} g_i^{(s)}, \quad S_R = \{i : r_i > 0\}. \quad (11)$$

在各客户成本已包含于 $g_i^{(s)}$ 的前提下，选择 S_R 可保证每个入选客户在所有压力情景下仍有正的逐人期望净收益。表 9 给出风险排序和稳健正收益集合；“下界”是 $\sum_{i \in S} \min_s g_i^{(s)}$ ，不是对未来现金流的置信区间。

表 9: 稳健策略的保守收益下界

策略	选择人数	覆盖率	逐人最坏净收益下界之和/元
稳健排序前 5%	352	5.00%	104595.98
稳健排序前 10%	704	10.00%	198611.50
稳健排序前 20%	1408	20.00%	354597.05
稳健正收益集合	3122	44.33%	506335.09

据此给出可落地的月度动态规则：

- D1.** 每个标签窗口重新计算数据漂移、校准曲线和合同分层流失率；若新窗口的校准误差或 AUC 超过预设门限，暂停自动扩大覆盖率。
- D2.** 根据竞争价格和宏观指标（补充采集后）估计或更新 $\delta_i^{(s)}$ ，同时重新审查 q_s, C_s, L ；在证据不足时沿用压力上界而不输出“已估计弹性”。
- D3.** 先用 $r_i > 0$ 的稳健集合做保守投放；若容量有限，按 r_i 排序。对月付且在网不足 12 个月者设置人工复核，避免一次性高额优惠伤害长期价值。
- D4.** 用随机对照实验记录“是否触达、优惠内容、是否续留和成本”，逐步把题面平均成功率替换为分层的实验估计；在实验完成前不把相关模型升级为个体 uplift 模型。

7 验证、局限与推广

本文使用了四类互补检查：(i) 数据行列、重复和结构性缺失审计；(ii) 列联表与交叉群体的独立描述；(iii) 留出集、五折 AUC、OOF 校准和非线性基准；(iv) 经济参数敏感性与外部冲击压力测试。图 4 的系数方向、表 6 的策略排序和表 9 的稳健下界均由同一求解入口生成，避免手工改写数字。

仍有以下边界：

- 横截面数据不能证明“降价、电子支票或缺少支持服务导致流失”；只能支持观测关联和风险排序。
- OOF 验证随机分层而非按时间切分；部署到未来月份前必须补做时间外推回测，检查概念漂移。
- $q = 0.35$ 是全体平均成功率，未区分客户可挽留性；Q3 的收益是期望决策值，不是承诺的实际利润。

4. Q4 的 logit 扰动是可解释的压力假设。没有竞争价格、宏观变量和外部时间序列时，不能把情景差异写成市场弹性估计。
5. 总费用与在网时长、月费用存在结构相关，系数表不宜用于单独制定价格政策；业务解释应回到分层实验。

若补充连续月份标签、触达记录、竞争价格、服务工单和地区信息，可将当前链条升级为时间切分的校准模型、分层 uplift 实验和带预算约束的多期优化；在此之前，本文的保守阈值和稳健集合是更适合上线试运行的接口。

8 结论

本题的核心不是对所有客户套用同一个分类器，而是把数学判据与运营约束接起来。数据证据显示，合同期限、服务组合、支付方式和在网时长是主要风险分层线索；参考编码 Logistic 模型在 OOF 上达到 0.8450 的 ROC-AUC，并输出可解释概率。把题面经济参数代入 $pqL - C$ 后，阈值 0.2143 将“是否干预”变为可复核不等式，OOF 评估下选择 3286 人的期望净收益约 63.02 万元。面对外部冲击，使用 logit 压力情景和逐人最坏得分可以保留明确的安全边界，但不越过数据能够支持的因果结论。

A 可复现说明与算法接口

求解器入口为 `models/solve_b_problem.py`，运行命令为：

```
python -X utf8 models/solve_b_problem.py --input "<附件路径>/校赛B题附件.csv"
--output runtime/solo-test/b_solution --seed 42
```

程序按以下顺序输出：

1. 读取并识别编码，执行式 (1) 的结构性清洗；
2. 生成 Q1 的关联表、分组率和交叉群体表；
3. 训练 Logistic 与梯度提升基准，产生留出、五折和 OOF 指标；
4. 用式 (9) 计算策略，用式 (10)–(11) 计算压力情景；
5. 写出聚合 CSV、JSON 和五张图。客户级风险明细只留在本地输出目录，不进入版本库。

本次复核环境为 Python 3.9.7、pandas 2.3.3、NumPy 2.0.2、SciPy 1.13.1、scikit-learn 1.4.2 和 Matplotlib 3.9.4；随机种子为 42。题面 DOCX 的 SHA-256 为 C2049336B8EF6D85BA5D52FC943D9DEB839E8A4A20D083807CC7B267A0C96C89，附件 CSV 的 SHA-256 为 7131CD7542BC248F090E26E1BEB40D22B9E9F1EC32D8C8854D71377A94B8D858。这些哈希用于锁定输入版本，不代表数据授权或官方格式确认。

B 证据文件清单

与本文数字对应的聚合证据位于 `paper/evidence/`。其中包括质量、关联、交叉群体、模型指标、校准、系数、策略敏感性、情景和稳健策略文件；完整文件名见该目录。证据文件不含客户编码；`risk_scores_local.csv` 只在本地运行目录生成。

参考文献

- [1] Hosmer, D. W., Lemeshow, S., Sturdivant, R. X. *Applied Logistic Regression*. Wiley, 2013.
- [2] Cramér, H. *Mathematical Methods of Statistics*. Princeton University Press, 1946.
- [3] Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830, 2011.